

MODELAMIENTO DE LA DUREZA DEL CONCRETO A TRAVÉS DE REDES NEURONALES ARTIFICIALES

Oscar Eduardo Caiza
Gustavo Colimba
Jonathan Maldonado
Juan Camilo Ortiz
Andrés Felipe Vargas

Pontificia Universidad Javeriana, Bogotá CO 110231, Colombia

1 Introducción

El desarrollo de la fortaleza o fuerza del concreto está determinado, principalmente, por la relación de agua y cemento, sin embargo, también está influenciada por el contenido de otros ingredientes (1). Actualmente, existen concretos con “ultra alto desempeño” (UHPFC, por sus siglas en inglés), el cual genera ventajas competitivas como baja porosidad, permeabilidad extremadamente baja, alta ductilidad y resistencia a la lixiviación, con respecto a un concreto común un corriente (2). Adicionalmente, este tipo de concretos pueden evitar la corrosión en las edificaciones, causada por el cloruro (3).

La industria del concreto en Colombia presentó cambios volátiles en la actividad de 1995 a 2005, en donde se evidenció un evidente crecimiento del sector (4). Hacia el 2019 la producción de concreto premezclado en Colombia ascendió aproximadamente un 5% con respecto al 2018 (5). Durante el segundo semestre de 2021, el sector de la construcción aumentó el PIB a precios constantes en el 17.6%, todo con relación al mismo trimestre de 2020 (6). Todo lo anterior para indicar que es una industria que viene en crecimiento en Colombia en los últimos años y a la cual hay que prestarle atención y generar innovación para el crecimiento de valor.

Una de las formas de generación de valor para la industria del concreto, y de la construcción en general, es mediante la evaluación del cemento de alto performance. Según varios estudios, una de las variantes para predecir y modelar el comportamiento de la fuerza del concreto, a partir de los materiales con los cuales se realiza es mediante la aplicación de redes neuronales artificiales (1). Estado del arte

1.1 Estimación de la Fuerza Compresiva del Concreto con Machine Learning

Dentro del campo de la ingeniería civil el estudio de materiales y específicamente del concreto es uno de los principales objetos a mejorar para el desarrollo de

construcciones. En este marco, desde inicios del siglo XX se ha buscado identificar la composición idónea del concreto, determinando en el año 1918 la ley de Abram. En esta ley se establece una relación inversa entre la fuerza compresiva del concreto y la relación agua-cemento que se utilice en la mezcla (7). El resultado de esta ley termina siendo que la para obtener la dureza óptima del concreto, se debe usar una proporción igual de agua y de cemento.

Aunque gran parte de la fortaleza del concreto depende la proporción de agua y cemento, esta ley no tiene cuenta la utilización de los demás componentes del concreto final (8). Yeh (2), en 1998 utilizando una muestra de diferentes composiciones para mezclas los componentes de agua, cemento, cenizas volátiles, escoria de horno, agua, superplastificante, grava y arena buscó a partir de la aplicación de redes neuronales artificiales la optimización del componente de fortaleza dependiendo de la composición de la mezcla. Encontrando nuevas características que tenían una relación fuerte con la fuerza compresiva como la relación entre agua-aglutinante y mostrando la efectividad de métodos de machine learning para encontrar las relaciones de la dureza con la composición de la mezcla del concreto.

Siguiendo el reto de lograr una combinación óptima para el conjunto de datos de Yeh; Cheng, Mahardika y Prayogo (9) postularon un proceso utilizando un Árbol de operaciones de la pirámide ponderada genéticamente que obteniendo resultados similares a los alcanzados a través de redes neuronales propone fórmulas explícitas que pueden ayudar a la utilización de los resultados en ambientes productivos. Por otro lado, probando la utilización de nuevos materiales con el objetivo de encontrar los más sostenibles (con una mayor duración y por lo tanto una mayor fuerza compresiva) Pham, Ngo, Nguyen y Truong (10) utilizan modelos de híbridos de machine learning para definir la mezcla con componentes de espuma.

De esta forma, la aplicación de técnicas para comprobar la fortaleza del concreto es ampliamente difundida. La utilización de nuevos métodos de machine learning se ha transformado en la herramienta más frecuente para validar las mezclas óptimas y así dar mejores resultados en la industria civil de los países.

1.2 Redes Neuronales

La historia de las redes neuronales tiene inicio en 1646 con Gottfried Leibniz, quien habló por primera vez de que el sistema nervioso podría ser considerado como mecanismo universal de computación. En 1943, Warren McCulloch y Harry Pitts crearon el primer modelo computacional para redes neuronales, basado en matemáticas y algoritmos llamados lógica de umbrales. Por último, a final de la década de 1950, Frank Rosenblatt, basado en el trabajo de McCulloch y Pitts, creó Perceptrón. Actualmente, una red neuronal artificial (RNA) modela la relación entre un conjunto de señales de entrada y una señal de salida, utilizando un modelo derivado de nuestro entendimiento de cómo un cerebro biológico responde a los estímulos de entradas sensoriales (11).

En términos generales, una red neuronal puede ser definida en términos de una función de activación, una topología de red y un algoritmo de entrenamiento. La función de activación transforma las señales de entrada combinadas de una neurona en una sola señal de salida. Las funciones de activación se pueden clasificar en las siguientes:







	Función	Rango	Gráfica
Identidad	$y = x$	$[-\infty, \infty]$	
Escalón	$y = \begin{cases} 1, & \text{si } x \geq 0 \\ 0, & \text{si } x < 0 \end{cases}$	$[0, 1]$	
	$y = \begin{cases} 1, & \text{si } x \geq 0 \\ -1, & \text{si } x < 0 \end{cases}$	$[-1, 1]$	
Lineal a tramos	$y = \begin{cases} 1, & \text{si } x > 1 \\ x, & \text{si } -1 \leq x \leq 1 \\ -1, & \text{si } x < -1 \end{cases}$	$[-1, 1]$	
Sigmoidea	$y = \frac{1}{1 + e^{-x}}$	$[0, 1]$	
	$y = \tanh(x)$	$[-1, 1]$	
Gaussiana	$y = Ae^{-Bx^2}$	$[0, 1]$	
Sinusoidal	$y = A \sin(\omega x + \varphi)$	$[-1, 1]$	

Ilustración 1. Tipos de funciones de activación (12)

A su vez, la topología de la red describe el número de neuronas en el modelo, así como el número de capas y la forma en la cual están conectadas. Finalmente, un algoritmo de entrenamiento especifica los pesos de conexión de las neuronas (11). En la Ilustración 2 y la Ilustración 3, se muestra gráficamente la topología de una red neuronal de capa sencilla y de múltiple capa, respectivamente.




Ilustración 2. Ejemplificación de red neuronal de capa sencilla.




Ilustración 3. Ejemplificación de red neuronal de múltiple capa.

2.2 Un algoritmo de luciérnaga modificado, un sistema experto en redes neuronales artificiales para predecir la resistencia a la compresión y a la tracción del hormigón de alto rendimiento.

Como definición importante de concreto o también llamado hormigón el cual es un conglomerado a partir de cemento, agregados de agua y otros componentes denominados adiciones minerales y aditivos químicos a continuación se presenta una revisión de un estudio relacionado con el tema de investigación.

Este estudio tiene como objetivo desarrollar un sistema experto basado en el modelo de red neuronal artificial (ANN) en asociación con un algoritmo de luciérnaga modificado (MFA). Esta investigación busca aplicar el algoritmo de luciérnaga modificado (MFA) para optimizar los pesos y sesgos de ANN para predecir eficazmente la resistencia a la compresión de HPC (Hormigón de alto rendimiento) en comparación con el concreto ordinario, que se compone de tres componentes principales que incluyen agua, agregados finos y gruesos y cemento, el HPC se complementa con un material cementoso adicional, por ejemplo, humo de sílice, nano-sílice, escoria de alto horno y cenizas volantes para mejorar su resistencia a la compresión (11).

Adicional a lo anterior las propiedades del HPC dependen de muchos elementos como las proporciones de la mezcla, la calidad del material y la edad del hormigón. De acuerdo con esto se tiene que:

predecir la resistencia a la compresión y a la tracción de HPC (Hormigón de alto rendimiento) es una tarea importante porque puede ayudar a programar las operaciones en las primeras etapas del diseño estructural, reduciendo así los requisitos experimentales. Por lo tanto, un método preciso para pronosticar la resistencia a la compresión de HPC puede reducir significativamente el tiempo y el costo (11).

2.2.1 Metodología

2.2.1.1 Sistema experto MFA-ANN

Red de neuronas artificiales: La construcción de la RNA se puede dividir en tres pasos principales: 1) definir las entradas y salidas del problema; 2) entrenar la red modificando los pesos y el sesgo de las capas de entrada, ocultas y de salida; y 3) probar el rendimiento de la red comparando valores predichos y valores reales.




Ilustración 4. Diseño esquemático de una red neuronal artificial para pronosticar la resistencia a la compresión del hormigón (13).

2.2.2.2 Algoritmo de luciérnaga Modificado: Este método metaheurístico inspirado en la naturaleza encuentra con precisión los óptimos tanto globales como locales. sigue tres reglas idealizadas principales:

1. Debido a que el género de las luciérnagas es unisex, una luciérnaga puede ser atraída por otras luciérnagas independientemente de su género
2. El atractivo y el brillo son correlativos entre sí, por lo que las luciérnagas menos brillantes se sentirán atraídas por las más brillantes.
3. El brillo de una luciérnaga se mide por el paisaje de la función objetivo (13).

2.2.2.3 Implementación de MFA en ANN: En la primera etapa el historial de datos es clasificado como datos de aprendizaje y de prueba, posteriormente se construye un conjunto de modelos a partir de los datos de aprendizaje y los resultados se evalúan mediante los datos de prueba.

El modelo entrenado en esta investigación es ANN con una función de aprendizaje de Levenberg-Marquardt. El proceso de entrenamiento de ANN es el procesamiento de optimización de la conexión entre neuronas en diferentes capas (13).

2.2.2.4 Resistencia a la compresión al hormigón de alto rendimiento: Se investigan ocho entradas que incluyen la cantidad de cemento, agua, escoria de alto horno, agregado grueso, agregado fino, superplastificantes, cenizas volantes y la edad de la prueba, mientras que la resistencia a la compresión (en MPa) es la salida.

2.3 Uso de una red neuronal artificial para predecir las propiedades de fractura de la zona de transición interfacial del hormigón a mesoescala.

El hormigón es un material heterogéneo de múltiples fases en el que la zona de transición interfacial (ITZ) entre los agregados y el mortero afecta significativamente el comportamiento de agrietamiento del hormigón, especialmente bajo carga de tracción (14).

2.3.1 Modelo de fractura de meso escala para hormigón: en primer lugar, se desarrolló mediante la generación y el embalaje de los agregados al azar. Aunque de manera realista los agregados deben tener bordes rugosos, es casi imposible mallar los agregados con bordes extremadamente irregulares en el modelado de elementos finitos.

Simplificando la forma agregada como el polígono con un tamaño aleatorio de 4-13 lados.




Ilustración 5. Generación del polígono irregular: (a) polígono regular; (b) vértice móvil; (c) vértice giratorio (13).

En este estudio, no se simula la fractura de los agregados y se asume que la ITZ es una interfaz de espesor cero.

2.3.2. Establecimiento de la red neuronal artificial y el análisis inverso.

La red neuronal artificial (ANN) se ha utilizado ampliamente para el aprendizaje, las predicciones y la toma de decisiones basadas en datos.

Primero: el conjunto de datos de entrenamiento se usa para ajustar el modelo

Segundo: el conjunto de datos de prueba se utiliza para proporcionar una evaluación imparcial de un ajuste final del modelo en el conjunto de datos de entrenamiento

Tercero: La validación consiste en evaluar un modelo dado mediante un conjunto de datos.

Para determinar las propiedades de fractura ITZ del concreto es el siguiente:

Primero, se debe obtener una solución conocida para el comportamiento general de fractura (es decir, la relación tensión-ancho total) con alta confiabilidad y precisión. Entonces, un meso-Se debe desarrollar un modelo de hormigón a escala compuesto por áridos, mortero e ITZ. Este modelo es capaz de obtener el desempeño estructural general y toda la curva tensión-ancho de fisura del concreto (14). Posterior a lo anterior se Selecciona la resistencia a la tracción y la energía de fractura de ITZ como las variables objetivo y los otros parámetros del material se tratan como constantes.

Para establecer el ANN, los valores iniciales para la resistencia a la tracción y la energía de fractura de ITZ se utilizan como datos de entrada y las curvas de tensión-ancho de fisura de las simulaciones correspondientes son datos de salida. Estos datos de entrada y salida se dividen aleatoriamente en conjuntos de datos de entrenamiento, prueba y validación. Luego, se crea en la ANN una función objetivo para calcular el error entre las salidas calculadas y la curva experimental de ancho de tensión-grieta. Para un valor de salida dado (es decir, la curva de ancho de fisura-tensión general), se usa un algoritmo de optimización para encontrar valores de ITZ optimizados que hacen que la función objetivo sea mínima (14).

Posteriormente lo que hacen es calcular el error entre los resultados numéricos y experimentales. Si el error cae por debajo de un valor umbral: se determinan los valores de ITZ y se llevan a cabo los procesos de análisis inverso. Si el error supera el valor umbral: Los resultados numéricos actuales se agregarán para volver a entrenar la red e invertir las propiedades de fractura de ITZ objetivo.

Los agregados en el modelo de hormigón heterogéneo se generan y empaquetan aleatoriamente. Por tanto, la heterogeneidad del hormigón afectará al agrietamiento del hormigón (14).

2.4 Un estudio comparativo sobre los modelos de predicción de la resistencia a la compresión para el hormigón de alto rendimiento que contiene nano sílice y escoria de cobre mediante análisis de regresión y redes neuronales artificiales.

En este estudio, los modelos de Análisis de regresión múltiple (MRA) y Red neuronal artificial (ANN) se construyen para predecir la resistencia a la compresión del concreto de alto rendimiento que contiene nano sílice y escoria de cobre como reemplazo parcial de cemento y agregado fino (15).

El hormigón de alto rendimiento (HPC) se refiere al tipo de mezcla de hormigón que tiene una trabajabilidad adecuada, desarrolla una alta resistencia y posee excelentes propiedades de durabilidad a lo largo de su vida útil prevista (15). Min – Hong Zhang y Jahidul islam han informado que la incorporación de nano sílice acelera la tasa de hidratación del cemento y contribuye a la alta resistencia inicial del hormigón (15).

2.4.1 Metodología: En este estudio, se han desarrollado cuatro modelos diferentes utilizando técnicas de MRA y ANN. Para cada modelo, se han variado los parámetros de entrada y salida tal como lo muestra la siguiente tabla.

ID de modelo	Variables dependientes	No. de muestras	ARM	ANA
M ₁	C, NS, A, SP	54	MRA ₁	ANN ₁
M ₂	C, NS, FA, CS, A, SP	180	MRA ₂	ANN ₂
M ₃	C, NS, FA, CS, A, SP	264	MRA ₃	ANN ₃

Ilustración 6. Resumen de los modelos generados (15).

2.4.1.1 análisis de regresión Múltiple: se basa en los valores del coeficiente de correlación (R), el coeficiente de determinación (R²), el valor p, la prueba F y el estadístico de Durbin-Watson.

2.4.1.2 Red neuronal artificial: Hay varios algoritmos que se pueden implementar en el modelado de redes neuronales artificiales, a saber, regularización bayesiana, Levenberg-Marquardt, BFGS Quasi Newton, gradiente conjugado de Powell-Beale, secante de un paso, descenso de gradiente, descenso de gradiente con impulso o tasa de aprendizaje adaptativo o ambos, gradiente conjugado de Fletcher-Powell, entrenamiento incremental de orden aleatorio con aprendizaje, resiliente, gradiente conjugado de Polak-Ribiere y entrenamiento por lotes con reglas de aprendizaje de peso y sesgo (12).

2 Metodología Red Neuronal – Topología de AutoModel RapidMiner

Para la solución de nuestro caso de estudio presentamos como alternativa la implementación de una red neuronal, en la presente sección se desarrolló el estudio de esta, además de realizar varias pruebas (Test) con modificaciones en sus parámetros y topologías y poder hacer un cotejo de resultados respecto a la precisión en la predicción del valor csMPa. En primer lugar, es necesario mostrar la correlación de las variables de entrada a nuestra red neuronal, como se puede ver en la siguiente Ilustración 7.




Ilustración 7. Matriz de correlaciones.

Como se puede apreciar en la Ilustración 7 existe una variable que casi no tiene valores que indiquen una correlación con otras variables, por lo tanto, más adelante en el Test 4 se eliminará la misma como un input de la red, con la finalidad de apreciar si esto aporta a la salida esperada.

A continuación, se muestran los resultados de la salida de una red neuronal que fue entrenada con los datos de estas variables y sus diferentes variaciones ayudadas por AutoModel de RapidMiner

3 Resultados

Tabla 1. Resultados obtenidos mediante la aplicación de redes neuronales.

Test	Parámetros	RMSE	Error absoluto	Coficiente de correlación (R^2)	Rankin mejor opción
1	Número de Capas: 4 Neuronas: <ul style="list-style-type: none"> • 8 inputs • 50 cada capa oculta • 1 output Función de activación: ReLu Epoch: 10	6.069	4.64	0.867	1
2	Número de Capas: 4 Neuronas: <ul style="list-style-type: none"> • 8 inputs • 5 y 10 capas ocultas • 1 output Función de activación: ReLu Epoch: 100	8.30	6.40	0.756	5
3	Número de Capas: 5 Neuronas: <ul style="list-style-type: none"> • 8 inputs • 5 en capa oculta • 1 output Función de activación: Tanh Epoch: 500	6.38	4.76	0.856	3
4	Número de Capas: 5 Neuronas: <ul style="list-style-type: none"> • 7 inputs • 5 en capa oculta • 1 output 	6.42	5.01	0.851	4

	Función de activación: Tanh Epoch: 500				
5	Número de Capas: 5 Neuronas: <ul style="list-style-type: none"> • 8inputs • capa oculta 1: 448 • capa oculta 2: 224 • Capa oculta 3: 112 • 1 output Función de activación: Relu Epoch: 500	6.208	4.73	0.946	2

A continuación, se presentan los dos mejores modelos obtenidos:

Prueba 1

La primera prueba consiste en ejecutar el automodel de rapidminer para verificar cuales son las sugerencias según los datos, esta prueba constituye la línea base de nuestras siguientes pruebas será la que tomaremos de referencia inicial, a partir de esta red generada automáticamente se irán modificando algunos valores para ver los resultados. Primero fue necesario cargar los datos, los cuales han sido divididos en un 60% para entrenamiento y 40% de prueba como lo sugiere la herramienta, luego se seleccionan los inputs del modelo que en este caso fueron 8, es decir en la capa de entrada se tienen 8 neuronas más 1 de bias, se tiene dos capas ocultas cada una con 50 neuronas con una función de activación ReLu y finalmente la capa de salida que consta de 1 neurona en la cual se tienen los valores de predicción del coeficiente csMPa. Se presenta también mediante la Ilustración 8 el comportamiento de la red, respecto a las fases de pruebas y entrenamiento usando la métrica RMSE y finalmente una comparativa mediante la Ilustración 9 entre el valor real y la salida de la red neuronal.

Detalle de la prueba

Row No.	csMPa	prediction(csMPa)	Deep Learning - Weights	
1	44.300	44.435	Attribute	Weight
2	43.700	47.847	age	0.819
3	36.450	37.494	slag	0.408
4	45.850	29.960	cement	0.361
5	28.020	25.247	superplasticizer	0.193
6	47.810	30.045	fineaggregate	0.095
7	52.910	37.879	flyash	0.077
8	39.360	44.100	coarseaggregate	0.068
9	41.840	47.168	water	0
10	44.210	48.505		

Ilustración 8. Valores de predicción y pesos de variables.




Ilustración 9. Regresión valores reales y predicción.

```

MSE: 36.839695
RMSE: 6.069571
R^2: 0.8678685
mean residual deviance: 36.839695
mean absolute error: 4.6416287
root mean squared log error: 0.1941728

```

Ilustración 10. Métricas obtenidas.




Ilustración 11. RMSE para el modelo: 10 epochs (izquierda) y 100 epochs (derecha).

Layer	Units	Type
1	8	Input
2	50	Rectifier
3	50	Rectifier
4	1	Linear

Ilustración 12. Topología de la red neuronal.

Prueba 5

Se presenta a continuación, mediante el uso de una herramienta de “keras” en python, la cual permite realizar un autoajuste de los parámetros necesarios para tener una optimización del modelo, los valores a cambiar como se indica en la Ilustración 13 son: número de neuronas en las capas ocultas, tasa de aprendizaje, función de activación y cantidad de epochs.

```
INFO:tensorflow:Oracle triggered exit
The hyperparameter search is complete. The optimal number of units in the first densely-connected
layer is 448 and the optimal learning rate for the optimizer
is 0.01.
```

Ilustración 13. Hiperparámetros del optimizados de keras tuner.

En las neuronas se pasa de un valor de 5 a 448, 224 y 112 respectivamente para las 3 capas ocultas propuestas. Luego la tasa de aprendizaje se cambia de 0.015 a 0.01 y se mantienen las epochs en 500. Obteniendo los siguientes resultados como se indica en las Ilustración 14.

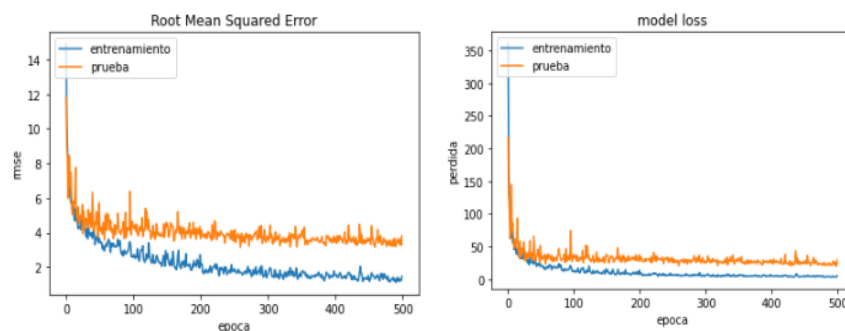


Ilustración 14. RMSE para el modelo (izquierda) y modelo de pérdida (derecha).

4 Conclusiones

Para el modelo 1.

- El valor de R^2 entre los valores reales y los precedidos es de 0.86 entre el valor csMPa real y la predicción del modelo, es decir se tiene una correlación positiva y perfecta, con lo que podemos concluir mediante este valor, la Ilustración 9 y los resultados presentados en la Ilustración 8 que el comportamiento de nuestra propuesta inicial es bastante aceptable y consideramos que para disminuir los falsos positivos se debería aumentar la cantidad de datos de entrenamiento, teniendo cuidado de no caer en un overfitting.
- Se observó que un bajo número de epoch influye directamente en el resultado esperado ya que en la Ilustración 11 izquierda se tiene un valor de 10 y se observó que existe una diferencia entre el entrenamiento y la prueba un valor de RSME de 6.069, ahora cuando se aumentó la cantidad de epochs se tiene una mejora en el valor de RMSE a 6.07 y en la Ilustración 11 derecha se aprecia esta mejoría.

Para el modelo 5:

- Se logró apreciar que keras tuner es una herramienta eficaz al momento de determinar el número de neuronas necesarias en las capas ocultas, y la tasa de aprendizaje, y así lograr una convergencia más rápida a la respuesta, sin embargo el modelo que mejor se ajusta a la necesidad de predecir el coeficiente

csMPa es el referente al test1, por lo tanto tener una gran cantidad de neuronas no necesariamente implica obtener un mejor rendimiento de la red, al igual que aumentar capas innecesarias a la red pueden ocasionar la inclusión de ruido y procesamiento innecesario también como se aprecia en la Ilustración 14.

5 Referencias

1. **Yeh, I.C.** *MODELING OF STRENGTH OF HIGH-PERFORMANCE CONCRETE USING*. s.l. : Cement and Concrete Research, 1998.
2. **Yeh Lai, Voo, Hejaz, Farzard and Saleem, Sarah.** *The construction process for pre-stressed ultra high performance concrete communication tower*. s.l. : Plos One, 2020].
3. **Mrakovčić, Silvija, Bede, Natalija and Ušić, Ivan.** *Analysis of Chloride Penetration Into High Performance Concrete*. s.l. : Annals of Maritime Studies, 2020.
4. **Latorre Cañon, Andrés, Delriue Alcaraz, Juan Carlos and Rodriguez Sanmiguel, Narcicio.** *La industrial del cemento en Colombia determinantes y comportamiento de la demana (1999-2005)*. s.l. : Universidad Nacional de Colombia, 2008.
5. **Sectorial.** *Cemento. Evolución de la Producción de Concreto Crece 5% en el Acumulado a Agosto de 2019*. [Online] 10 18, 2019. [Cited: 09 18, 2021.] <https://www.sectorial.co/informativa-cemento-y-concreto/item/268195-evoluci%C3%B3n-de-la-producci%C3%B3n-de-concreto-en-agosto-de-2019>.
6. **DANE.** *Construcción. Indicadores Económicos Alrededor de la Construcción (IEAC)*. [Online] 2021. [Cited: 09 18, 2021.] <https://www.dane.gov.co/index.php/estadisticas-por-tema/construccion/indicadores-economicos-alrededor-de-la-construccion>.
7. **Pumnia, B.C, Ashok, Join and Arun, Jain.** *Cement Concrete*. s.l. : Basic Civil Engineering, LAXMI Publications, 2021. pp.141-165..
8. **Popovics, S.** *Analysis of the Concrete Strength versus Water Cement Ratio Relationship*. [Online] 1990. <https://www.concrete.org/publications/internationalconcreteabstractsportal.aspx?m=details&ID=1944..>
9. **Min-Yuan Cheng, Pratama Mahardika and Dobby Prayogo.** *High-performance concrete compressive strength prediction using Genetic Weighted Pyramid Operation Tree (GWPOT)*. s.l. : Engineering Applications of Artificial Intelligence, vol. 29, pp. 104-113, 2014.
10. **AD Pham, et al.** *Hybrid machine learning for predicting strength of sustainable concrete*. s.l. : Soft Computing, vol. 24, pp. 14965-14980, 2020.
11. *Redes Neuronales*. **García, Juan Carlos.** Bogotá : Pontificia Universidad Javeriana, 2020. Clase de Métodos y aplicaciones analíticas 2. p. 3.
12. *Introduccion, s.l.: Neural Networks and Learning Machines*. **Haykin, Simon.** 2003. pp 1-46.

13. *A modified firefly algorithm-artificial neural network expert system for predicting compressive and tensile strength of high-performance concrete.* **Biu, Dac-Khuong, et al.** s.l. : ScienceDirect, 2018.
14. **Xi X, Yin Z, Yang S, Li C-Q.** *Using artificial neural network to predict the fracture properties of the interfacial transition zone of concrete at the meso-scale.* 2020.
15. **Chithra S, Kumar SRRS, Chinnaraju K, Alfin Ashmita F.** *A comparative study on the compressive strength prediction models for High Performance Concrete containing nano silica and copper slag using regression analysis and Artificial Neural Networks.* 2016.